

Raport - Adam Kusiakiewicz, Oskar Gierlicz

Importowanie bibliotek oraz przedstawienie danych po ich załadowaniu



Przedstawienie kolumn w train.csv oraz opis kluczowej dla nas kolumny SalePrice

Dokładna mapa korelacji zawierająca 10 najbardziej istotnych korelacji




Sprawdzenie pustych danych i usunięcie kolumn które je posiadają

```
[7]: # sprawdzenie pustych danych
       total = data.isnull().sum().sort_values(ascending=False)
percent = ((data.isnull().sum() / data.isnull().count()) * 100).sort_values(ascending=False).round(2)
empty_values = pd.concat([total, percent], axis=1, keys=['Total', 'Percent'])
empty_values = empty_values.head(20)
       empty_values
[7]:
                          Total Percent
               PoolQC 1453
                                     99.52
         MiscFeature 1406
                                     96.30
                  Alley
                          1369
                                     93.77
                                     80.75
                 Fence
                           1179
         MasVnrType
                            872
                                     59.73
          FireplaceQu
                            690
                                     47.26
         LotFrontage
                            259
                                      17.74
          GarageYrBlt
                             81
                                       5.55
         GarageCond
                             81
                                       5.55
          GarageType
                             81
                                       5.55
         GarageFinish
                             81
                                       5.55
          GarageQual
                             81
                                       5.55
       BsmtFinType2
                             38
                                       2.60
       BsmtExposure
                             38
                                       2.60
            BsmtQual
                             37
                                       2.53
            BsmtCond
                             37
                                       2.53
        BsmtFinType1
                             37
                                       2.53
          MasVnrArea
                              8
                                       0.55
             Electrical
                                       0.07
```

0

0.00

Przedstawienie odstających wartości SalePrice



Stworzenie danych do trenowania i ich optymalizacja


```
[11]: # usuwanie odstających wartości GrLivArea
data = data.drop(data[data['GrLivArea'] > 5000].index)
data['GrLivArea'].plot.box()# dane do uczenia, usunięcie kolumn typu Object uniemożliwiających nauczenie modelu XGBoosterem oraz
train_X = data.loc[:,:'SaleCondition']
train_y = data['SalePrice'].to_numpy()
test_X = test.copy()
numeric_cols = train_X.dtypes[train_X.dtypes != 'object'].index

train_X = train_X[numeric_cols]
test_X = test_X[numeric_cols]
train_X, test_X, train_y
```

Utworzenie funkcji do sprawdzenia poprawności predykcji, nauka modelu

```
[12]:
      from sklearn import metrics
      from sklearn.model_selection import cross_val_score
      def cross_val(model):
          pred = cross_val_score(model, train_X, train_y, cv=10)
          return pred.mean()
[13]:
     #przyuczenie modelu XGBRegressor danymi treningowymi
      model = XGBRegressor()
      model.fit(train_X, train_y, verbose=False)
[13]: <sub>v</sub>
                                        XGBRegressor
     XGBRegressor(base_score=None, booster=None, callbacks=None,
                   colsample_bylevel=None, colsample_bynode=None,
                   colsample_bytree=None, device=None, early_stopping_rounds=None,
                   enable_categorical=False, eval_metric=None, feature_types=None,
                   gamma=None, grow_policy=None, importance_type=None,
                   interaction_constraints=None, learning_rate=None, max_bin=None,
                   max_cat_threshold=None, max_cat_to_onehot=None,
                   max delta step=None, max depth=None, max leaves=None,
                   min_child_weight=None, missing=nan, monotone_constraints=None,
                   multi_strategy=None, n_estimators=None, n_jobs=None,
                   num_parallel_tree=None, random_state=None, ...)
[14]:
      predictions = model.predict(test_X)
[15]: cross_val(model)
[15]: 0.8586327868564967
[16]: # Ewaluacja modelu na danych treningowych
      train_predictions = model.predict(train_X)
      mse = mean_squared_error(train_y, train_predictions)
      r2 = r2_score(train_y, train_predictions)
      print(f'Mean Squared Error (MSE): {mse}')
      print(f'R-squared (R2): {r2}')
      Mean Squared Error (MSE): 2446343.272112987
      R-squared (R2): 0.9996123567559827
```

Wykres przewidywanych wartości vs. rzeczywiste wartości



Stworzenie submission

